Upravljanje

Veljko Petrović
Oktobar, 2022

Upravljanje superračunarskim sistemima

Podešavanje za performanse

Čime to moramo da upravljamo?

- Nema nekakve magije u HPC klasteru.
- To su stvarno samo Linux računari u mreži.
- Brzi računari povezani brzom mrežom, istina, ali to je sve.
- OpenMP programi su samo multi-threaded programi na jednom računaru. To se pokreće na isti način kao i svaki drugi program—to ste probali.
- OpenMPI tehnologija je neophodna da se uključi više čvorova.
- Tu se programi moraju pokretati posebnom komandom i to na svakom čvoru. Kada pokretati koliko programa i koje im resurse dodeliti... to je dosta posla da se radi rukom čak i na malom klasteru.

Upravljanje HPC klasterima

- Rešenje je specijalizovan softver koji služi da upravlja čvorovima i pokreće stvari kad mi hoćemo kako mi hoćemo.
- Softver se tipično sastoji od servisa koji rade na raznim delovima HPC klastera i komandama koje komuniciraju sa tim servisima.

Resursi koje kontroliše upravljački softver

- Čvorovi za računanje.
  - Osnovna stvar koja se kontroliše. Na svaki računar se moraju slati podaci, pokretati procesi, gasiti procesi, itd.
- Procesorska jezgra.
  - U okviru jednog računara je neophodno alocirati individualna jezgra i to na drugačiji način budući da su njihove karakteristike drugačije.
- Računarske veze.
  - Mreža u klasterima može biti jako kompleksna i heterogena. Upravljački softver se stara i da to radi kako treba.
- Eksterna memorija.
  - Upravljački softver se stara da je eksterna memorija dostupna i maksimalno performantna.
- I/O
  - Komunikacija sa spoljnim svetom ne može biti ad hoc.
- Akceleratori.
  - U heterogenim sistemima akceleratori proračuna (najčešće ali ne uvek %GPU%) su odvojen resurs koji se posebno alocira i posebno programira.

Ključni koncepti upravljačkog softvera

- Glavni koncept su zadaci (jobs) koji predstavljaju jednu celinu koju korisnik hoće da pokrene.
- Zadaci mogu biti:
  - Interaktivni (interactive). — Postoji ljudski operator.
  - Automatski (batch). — Nema operatora. Najčešće zadaci su ovakvi.
- Iako mogu biti monolitni, tipično zadaci se sastoje od više koraka (task/step). Ono što karakteriše korake jeste da mogu imati potpuno različite zahteve nad resursima.
- Zadaci idu u redove (queue) izvršavanja i koji od zadataka koji stoje u redu se izvršava kada određuje proces reda izvršavanja (scheduling)

Faktori koji utiču na proces reda izvršavanja

- Dostupnost neophodnih resursa.
  - Ako nema gde da se nešto izvrši onda se sigurno neće izvršiti.
- Prioritet.
  - U zavisnosti ko zahteva izvršavanje i šta je priroda posla može da dođe na red ranije ili kasnije.
- Korisnički budžet resursa.
  - Svaki korisnik može imati fiksnu količinu resursa koju sme da angažuje.
- Ograničenje broja zadataka.
  - Svaki korisnik može imati ograničeni broj zadataka koji sme zatražiti u nekom trenutku.
- Procenjeno vreme izvršavanja.
  - Kada zadajemo zadatak uvek navodimo koliko vremena tražimo.

Faktori koji utiču na proces reda izvršavanja

- Ostvareno vreme izvršavanja.
  - Zadatak može biti prekinut u zavisnosti od toga koliko dugo se već izvršava.
- Uslovljenost zadatka.
  - Zadaci mogu zavisiti od završetka drugih zadataka.
- Događaji.
  - Neki zadaci se samo dešavaju kada se na nivou celog sistema desi nekakav događaj.
- Dostupnost operatora.
  - Interaktivni zadaci su samo mogući ako ima neko fizički prisutan za terminalom.
- Dostupnost licence.
  - Ponekad naš kod zahteva licence koje se prodaju po jezgru. To znači da je to samo još jedan resurs koji treba alocirati.

Popularni alati za upravljanje HPC sistemima.

Simple Linux Utility for Resource Management (SLURM) — moćno, proširivo FOSS rešenje. Portable Batch System — Alternativa koja je nekad bila komercijalan kod, a sada postoji u FOSS varijanti. OpenLava — Još jedna alternativa. Moab Cluster Suite — Komercijalan softver fokusiran na ekstremnu skalabilnost. LoadLeveler — IBM proizvod prvobitno namenjen za AIX.
Univa Grid Engine — Oracle/Sun rešenje za heterogene računarske sisteme. HTCondor — FOSS rešenje za high-throughput coarse-grained HPC. OAR — Rešenje fokusirano oko data-intensive problema Hadoop Yet Another Resource Negotiator — Rešenje za map-reduce.

SLURM

Simple Linux Utility for Resource Management (SLURM)

SLURM

Zašto fokus na alat?

- Uopšteno govoreći, nije svrha ovakvog kursa da vam se čitaju uputstva odnosno `man` stranice.
- No, ipak će tu i tamo biti baš toga.
- Što?
- Pa ovde je razlog jednostavan: kroz razumevanje parametara i komandi SLURM sistema imamo priliku i da naučimo:
  - Šta su faktori u upravljanju klasterima?
  - Kako se pažljivim upravljanjem resursima podižu performanse sistema i naročito performanse po utrošenom novcu?

- Kao bonus, takođe možete da naučite i kako se SLURM može koristiti što će vam biti od koristi.

Zašto je SLURM odličan?

- Jednostavan
- Gotovo beskonačno skalabilan:
- SLURM se koristi, na primer, na TaihuLight mašini sa nekih 40 000 CPU-ova i 10 000 000 jezgara.
- Od najbržih 10 računara oko 5 koristi SLURM. (podatak je malo zastareo i stvarni broj osciluje, ali obično je oko pola)
- 1000 zadataka se može zakazati po sekundi a 500 izvršiti.
- Podržava heterogene tehnologije

Arhitektura SLURM sistema

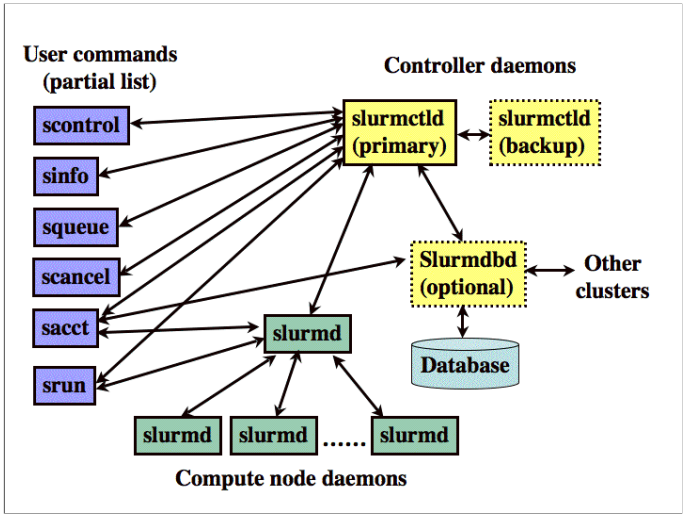

Grupisanje elemenata upravljanja u SLURM sistemima

- Čvorovi se mogu ubacivati u particije.
- Particije mogu biti:
  - Disjunktne
  - Preklapajuće
- Particije odgovaraju redovima izvršavanja
- Zadaci se grupišu u nizove zadataka koje odlikuju isti parametri izvršavanja.

Raspored izvršavanja (scheduling) u SLURM sistemima

- Ovo je sve proširivo, ali grubo govoreći imamo tri različita pristupa koja rade istovremeno.
- Raspored izvršavanja vođen događajima.
- Ukupni raspored izvršavanja.
- Unazad propagirajući raspored izvršavanja.

Raspored izvršavanja vođen događaijma

- Ovo je najjednostavniji način da se rasporede zadaci.
- Takođe je najbrži.
- Kada god se promeni status sistema (neki čvor se uključi, neki zadatak se završi, itd.) pokrene se ovaj algoritam.
- Algoritam uzme određeni broj zadataka sa prednjeg kraja reda i analizira ih u skladu sa ranije pomenutim faktorima.
- Sve što je nazad u redu se ignoriše dok ne stigne na prednji kraj.
- Ovo je brzo ali može dovesti do ne baš efikasne raspodele.

Ukupni raspored izvršavanja.

- Ukupni algoritam se pokreće samo povremeno zato što mora da posmatra sve zadatke koji su zakazani.
- Ovo ga čini sporim.
- Balans između efikasnijeg sistema rasporeda zadataka i usporenja usled troškova sistema se postiže povremenim pokretanjem koje sprečava da se nisko-efikasne situacije u rasporedu propagiraju.

Unazad propagirajući raspored izvršavanja.

- Naročit primer ne-efikasnosti jeste kada imamo zadatke niskog prioriteta a velikih zahteva.
- Jasno je da oni moraju da čekaju, ali ako stalno stižu prioritetniji poslovi, čekaće zauvek.
- Unazad propagirajući sistem za raspored analizira očekivano vreme kada svi poslovi treba da počnu, koliko treba da traju, i do kada se izvršavaju i traži vremena gde se izvršavanje nisko-prioritetnih poslova može udenuti tako da ne izazove kašnjenja u opštem rasporedu sistema.

Napredni koncepti u sistemu rasporeda izvršavanja SLURM

- Gang scheduling
- Preemption
- Generic resource allocation
- Trackable resources.
- Elastic computing.
- High-throughput computing.

Gang scheduling

- Mehanizam gde poslovi koji imaju slične prohteve za resursima dele iste resurse tako što jedni drugima predaju ekskluzivnu kontrolu.
- Najbolje radi ako imamo particiju čija konfiguracija odgovara prohtevima te klase poslova.
- Particije baš za to i služe.
- Mehanizam odredi dužinu alokacije (koja se zove ‘timeslice’ i konfigurabilna je) i kada god prođe jedan timeslice suspenduje tekući zadatak i aktivira suspendovan zadatak iste klase zahteva koji najduže čeka u suspendovanom stanju.
- Ovo jako liči na to kako se radi mulit-tasking na računarima sa jednom niti izvršavanja.

Preemption

- Mehanizam gde zadaci nižeg prioriteta mogu da se zaustave kada se alociraju zadaci višeg prioriteta kojima trebaju resursi koji su već u upotrebi.
- Radi isto kao gang scheduling sa tim da:
  - Iniciranje algoritma ne radi proticanje vremena, no alokacija resursa za nov zadatak.
  - Promena ko se izvršava nije u round-robin sistemu, no je vođena prioritetom.

Generic resources

- Odnosi se na posebne hardverske module koje može da ima nekakav čvor i koji ga, stoga, čine osobenim.
- Šta je to?
  - GPU
  - MIC
  - A, u budućnosti?
    - FPGA (nije više budućnost)
    - Kripto-modul
    - Kvantni računar
    - Kvantni simulator kaljenja
    - Neuro-akcelerator (nije više budućnost)

Generic resources

- Šta god da je generički resurs, mi možemo da zahtevamo čvor koji ga ima i sistem za raspored izvršavanja će voditi računa o tom zahtevu.
- Menadžment GRES-ovima nije baš savršen: suspendovanje zadataka trenutno ne oslobađa GRES-ove zato što se postavlja pitanje šta GRES može da sačuva a šta ne i šta je “bezbedno početno stanje” za GRES.
- Praktično, za nas, readback iz GPU memorije je... pipava stvar.

Trackable resources.

- SLURM ima mehanizam koji omogućava da se pažljivo prati i beleži upotreba raznih resursa (TRES):
  -
  - Bafera
  - Energije
  - GRES-ova
  - Licenci
  - Memorija
  - Čvorova
- Ovo omogućava dijagnostiku i, tužno je reći, naplatu.

Elastic computing

- Mehanizam kojim sistem za upravljanje resursima može da analizira trenutne prohteve sistema i menja veličinu sistema na adekvatan način.
- Sistem se može smanjiti tako što se čvorovi za kojima nema potrebe automatski isključe.
- Kako se povećava? Normalno nikako, ali ako je u pitanju cloud-baziran sistem, moguće je raditi automatski provisioninig još resursa po potrebi, ili barem dok Amazonu ne ponestane.
- Naravno to košta stoga ovaj deo mora biti konfigurisan izuzetno pažljivo.

High-throughput computing

- HTC je poseban scenario u okviru HPC problema gde je najprirodniji način da se problem opiše jeste preko jako velikog broja slabo povezanih zadataka.
- Idealan primer jeste renderovanje: svaki frejm je za sebe, a potencijalno želimo jako mnogo frejmova.
- Film od 90 minuta, na kraju krajeva, zahteva da renderujemo 129600 frejmova.
- Stoga SLURM ima posebnu logiku za slabo povezane mnogobrojne poslove koja dozvoljava da se pokrene po 500 takvih poslova u sekundi.

Komanda `srun`

- Najosnovnija komanda SLURM sistema je `srun`
- Opšta sintaksa komande je: `srun [<options>] <executable> [<arguments>]`
- Značenje je da se sa određenim opcijama pokreće u okviru klastera komanda `executable` kao zadatak
- Ako se `srun` pokrene u okviru već pokrenutog zadatka definiše ne nov zadatak već nov korak.
- Kompleksnost ove naizgled jednostavne komande jeste u opcijama koje su često ključne za dobro izvršavanje

`-N` opcija

- Opcija `-N` određuje broj čvorova koji se traži za komandu
- Mora imati makar jedan broj posle sebe, taj broj je minimalan broj čvorova koji tražimo.
- Može i da ima dva broja u obliku `-N<n1>-<n2>`
  - `n1` je minimalni broj čvorova
  - `n2` je maksimalni broj čvorova

`-n` i `-c` opcije

- `-n` opcija služi da se podesi broj procesa koji će se pokrenuti
- Svaki proces je jedna instanca naše aplikacije
- Da bi ovo imalo smisla nadamo se da naša aplikacija zna kako da se ponaša u takvom okruženju.
- Podrazumevano je da 1 proces dobije 1 čvor
- Ovo menja `-c` opcija ona određuje koliko će jezgara biti alocirano po svakom procesu. To omogućava da imamo višestruke ali i više-nitne procese, tj. `OpenMPI` + `OpenMP`.
- Ako bi zvršili `srun -n4 -c8 app0` onda bi pokrenuli app0 četiri puta i to tako da svako pokretanje zauzme barem osam jezgara. To znači da ako imamo sistem sa po 16 jezgara po čvoru zauzećemo 2 čvora.

`--mincpus` opcija

- Možemo komplikovati stvar tako što koristimo ovu opciju, jednu od mnogih koja postavlja ograničenje na tip čvora koji može da se koristi
- Sintaksa je, na primer, `--mincpus=32` što, kao opcija, bi reklo da se naš program može izvršiti isključivo na čvorovima koji imaju bar 32 procesora/jezgra/niti (terminologija je malo labava, ali se misli na 32 paralelna izvršavanja).
- Ako bi komandu sa prošlog slajda promenili da bude `srun -n4 -c8 -mincpus=32 app0` pokrenuli bi 4 procesa app0, svaki bi dobio 8 jezgara i svi bi bili na jednom čvoru sa 32 jezgra pod uslovom da takav postoji.

Labava terminologija

- Budući da je ponekad nejasno šta se misli pod CPU ovih dana, SLURM uvodi jasnu terminologiju i komande koje manipulišu tim jasnim terminima u svrhu uvođenja ograničenja
- Po SLURM terminologiji:
  - Core je fizičko jezgro kojih je tipično više po čipu
  - Socket je fizički čip utaknut u ZIF utičnicu na nekom računaru
  - Thread je sistemska nit izvršavanja
- Opcije su:
  - `--cores-per-socket=<vrednost0>`
  - `--sockets-per-node=<vrednost1>`
  - `--threads-per-core=<vrednost2>`
- Ovo se može napisati i brže ovako:

  - `-B<vrednost1>[:<vrednost0>[:<vrednost2>]]`

`-m` opcija

- Ova opcija podešava kako se procesi raspoređuju između čvorova/procesora itd.
- Ima izuzetnog uticaja na performanse i “tačne” vrednosti jako zavise od toga kako naš kod radi i kako funkcioniše lokalnost.
- Sintaksa je: `-m<nodeDist>[:<socketDist>[:<coreDist>]][,{Pack,NoPack}]`

A kako radi `nodeDist`?

- * — podrazumevana opcija, najčešće block
- `block` — procesi će biti dodeljeni redom čvoru dok ne ponestane resursa, te će onda biti slati dalje.
- `cyclic` — procesi se dele po čvorovima tako što se da jedan prvoj, pa onda drugi drugoj i tako dok ne ponestane mogućih čvorova a onda se počinje od prvog, opet.
- `plane=<n>` — stavi n procesa na jedan čvor i onda ide dalje da stavi n procesa na drugi čvor i tako.
- `arbitrary` — čita ponašanje iz sistemske promenljive

`coreDist` i `socketDist`

- Rade isto kao `nodeDist` samo što:
- Podrazumevani režim je `cyclic`
- `Cyclic` će grupisati zadatke po jezgru/procesoru
- `Fcyclic` je neophodan da bi se zadaci među njima raspoređivali po 100% round-robin pristupu

`Pack` i `NoPack`

- `Pack` i `NoPack` su hintovi sistemu koji određuju kako se sistem ponaša kada ima “izbor”
- `Pack` kaže da se procesi rasporede tako da maksimalno popune čvor
- `NoPack` kaže da se procesi rasporede tako da podela po alociranim resursima bude maksimalno fer, tj. ravnomerna

`-w` opcija

- Dobija kao parametar ili listu čvorova koje hoćemo da alociramo poimence ili putanju do fajla gde se ta lista čvorova nalazi
- Ima više smisla u malim klasterima gde ponekad znamo tačno šta hoćemo
- U sistemima sa 40 000 procesora... ima manje smisla.

Alokacija memorije

- Možemo tražiti memoriju po čvoru sa komandom `–mem=<m>` gde je `<m>` broj megabajta koji se alocira za zadatak.
- Možemo i tražiti memoriju tako što specificiramo koliko nam treba memorije po procesoru koristeći `–mem-per-cpu = <m>` na isti način.

Automatsko podešavanje

- Možemo zatražiti pomoć sistema tako što sugerišemo kakav je tip problema sa kojim se suočavamo koristeći opciju `--hint=<type>` gde je tip jedno od:
  - `compute_bound` — algoritmu je usko grlo proračun, tako da se alociraju sva jezgra u svakom čipu sa po jednom niti po jezgru.
  - `memory_bound` — algoritmu je usko grlo memorija, tako da se koristi po jedno jezgro u svakom čipu i jedna nit po jezgru
  - `multithread` — koristi više niti po jezgru
  - `nomultithread` — nemoj koristiti više niti po jezgru

Ograničavanje broja procesa

- Možemo podesiti da se nad jednim čvorom, čipom, ili jezgrom izvršava ne više od neke vrednosti n procesa kroz sintaksu:
  - `--ntasks-per-core=<n>`
  - `--ntasks-per-socket=<n>`
  - `--ntasks-per-node=<n>`
- `--ntasks-per-node=<n>` je naročito važna opcija jer ako se tu stavi 1, to je idealno za aplikacije koje koriste `OpenMP` kombinovan sa `OpenMPI` budući da svaki čvor dobije jedan proces koji onda koristi niti za paralelizam unutar čvora.

Ekskluzivnost

- Opcija `--exclusive` nam omogućava da zahtevamo da ne delimo čvorove sa drugim zadacima
- Ovo može biti bitno ako znamo da će rezultujuće zagušenje ugroziti performanse i našeg posla i tuđeg

GRES ograničenje

- `--gres` opcija ima sintaksu `--gres=<resource_list>` gde je sintaksa za `resource list` takva da se sastoji od zarezima odvojene liste resursa, a resurs ima sintaksu koja je: `<name>[[:<type>]:count]`
- Recimo `srun -N16 --gres=gpu:kepler:2 app0` će startovati `app0` na 16 čvorova koji moraju imati (i za upotrebu ove aplikacije alocirati) po 2 GPU-a tipa Kepler.

`-C` opcija

- Možemo anotirati čvorove sa osobinama.
- `-C` opcija nam kasnije dozvoljava da tražimo čvor sa baš tim, anotiranim osobinama.
- Specifikacija za `-C` se piše odamh posle u znacima navoda i sastoji se od imena opcija razdvojenih sa `&` i `|` kao `AND` i `OR` operatorima.
- Takođe ima posebna sintaksa oblika `srun -N8 -C '[rack1|rack3|rack5]' app0`
- Ovo pokreće app0 na osam čvorova koji moraju da budu ili rack1 ili rack3 ili rack5.

`-t` opcija

- Koliko vremena u satima:minutima:sekundama želimo da radi naš softver.
- Kada to vreme istekne dobijamo `TERM` signal
- Ako ne uradimo nešto sa tim `TERM` dobijemo uskoro i `KILL` signal

Signali

- `TERM? KILL?`
- Unix ima svoju filozofiju komunikacije između procesa
- Jedan od glavnih jesu signali: softverski prekidi koji označavaju da se u sistemu desio nekakav događaj.
- Ponekad ih generišu drugi procesi, ponekad sam operativni sistem, a ponekad korisnik direktno.
- Signali imaju različito značenje
- Može se dobiti kompletna lista iz operativnog sistema

Signali

```
[veljko@ftn ~]$ kill -l
 1) SIGHUP       2) SIGINT       3) SIGQUIT
4) SIGILL       5) SIGTRAP
 6) SIGABRT      7) SIGBUS       8) SIGFPE
9) SIGKILL     10) SIGUSR1
11) SIGSEGV     12) SIGUSR2     13) SIGPIPE
14) SIGALRM     15) SIGTERM
16) SIGSTKFLT   17) SIGCHLD     18) SIGCONT
19) SIGSTOP     20) SIGTSTP
21) SIGTTIN     22) SIGTTOU     23) SIGURG
24) SIGXCPU     25) SIGXFSZ
26) SIGVTALRM   27) SIGPROF     28)
SIGWINCH    29) SIGIO       30) SIGPWR
31) SIGSYS      34) SIGRTMIN    35)
SIGRTMIN+1  36) SIGRTMIN+2  37) SIGRTMIN+3
38) SIGRTMIN+4  39) SIGRTMIN+5  40)
```

Reakcija na signale

- Svaki tip signala ima jednu podrazumevanu akciju iz sledećeg skupa:
  - `Term`
    - Proces koji dobija signal se terminira.
  - `Ign`
    - Proces koji dobija signal ga ignoriše.
  - `Core`
    - Podrazumevana akcija jeste da se terminira proces i da se u fajl izbaci sva memorija procesa.
  - `Stop`
    - Proces se pauzira.
  - `Cont`
    - Proces se nastavi ako je pauziran.

Namena signala

Ime signala	Broj signala	Reakcija	Svrha
SIGHUP	1	Term	Prekinuta veza na kontrolnom terminalu, odn. smrt kontrolišućeg procesa.
SIGINT	2	Term	Kontrol-C
SIGQUIT	3	Core	Quit sa tastature
SIGILL	4	Core	Ilegalna instrukcija
SIGABRT	6	Core	Abort signal

Namena signala

Ime signala	Broj signala	Reakcija	Svrha
SIGFPE	8	Core	Floating-point greška
SIGKILL	9	Term	Ubijanje procesa
SIGSEGV	11	Core	Memorijska greška
SIGPIPE	13	Term	Greška u pisanju u dvosmerni bafer
SIGALRM	14	Term	Tajmer
SIGTERM	15	Term	Signal za terminaciju

Namena signala

Ime signala	Broj signala	Reakcija	Svrha
SIGUSR1	10	Term	Rezervisan za korisnika.
SIGUSR2	12	Term	Rezervisan za korisnika.
SIGCHLD	17	Ign	Dete-proces je prekinut.
SIGCONT	18	Cont	Nastavi izvršavanje.
SIGSTOP	19	Stop	Pauziraj izvršavanje.
SIGSTP	20	Stop	Pauziraj izvršavanje (pokrenut sa terminala)

Namena signala

Ime signala	Broj signala	Reakcija	Svrha
SIGTTIN	21	Stop	Komunikacija sa terminalom za pozadinski proces
SIGTTOU	22	Stop	Komunikacija sa terminalom za pozadinski proces
SIGBUS	7	Core	Greška magistrale
SIGPOLL	29	Term	Sinonim za SIGIO
SIGPROF	27	Term	Tajmer za profiliranje je istekao
SIGSYS	31	Core	Greška u sistemskom pozivu.

Ime signala	Broj signala	Reakcija	Svrha
SIGTRAP	5	Core	Breakpoint dostignut.

Ime signala	Broj signala	Reakcija	Svrha
			veličine fajla.
SIGIOT	6	Core	Isto što i SIGABRT.
SIGSTKFLT	16	Term	Stek greška na koprocesoru. (Nekorišćeno)
SIGIO	29	Term	I/O sada moguć.
SIGPWR	30	Term	Greška sa napajanjem.

Namena signala

Ime signala	Broj signala	Reakcija	Svrha
SIGURG	23	Ign	Hitna reakcija na socket-u.
ISGVTALRM	26	Term	Virtualni alarm
SIGXCPU	24	Core	Potrošeno svo CPU vreme.
SIGXFSZ	25	Core	Potrošeno ograničenje

Slanje signala

`kill -<signal> <pid>` tj. `kill -SIGUSR1 10366`

Slanje signala

```c
#include <signal.h>
#include <stdio.h>
#include <unistd.h>

int main(){
  for(int i = 1; i < 99999999;i++){
    prinf("%d\n", i);
    if(i == 4817){
      kill(getpid(), SIGTERM);
    }
  }
  return 0;
}
```

Reagovanje na signal

```c
#include <signal.h>
#include <stdio.h>
#include <unistd.h>

void signalCallback(int sig){
  printf("Primio: %d\n", sig);
}

int main(){
  for(int i = 1; i < 99999999;i++){
    prinf("%d\n", i);
    if(i == 4817){
      kill(getpid(), SIGTERM);
    }
    if(i == 5993){
```

Zakazivanje

- Jako je dobra ideja da se ne specificira samo vreme nego i vrednosti za `--begin` i `--deadline` opciju koje traže idealno vreme pokretanja i rok do koga se proračun treba završiti.
- Ovo omogućava inteligentnom sistemu za raspored izvršavanja da udene neke procese pre našeg na način koji nas ne usporava.
- Mnoge politike super-računara apsolutno zahtevaju ovakva podešavanja i to sa dobrim razlogom.

`-J` opcija

- Omogućava da se specificira ime zadatka koje je različito od imena aplikacije.
- Čisto od administrativne vrednosti.

`--checkpoint` opcije

- Opcija `--checkpoint=<time>` omogućava da se specificira koliko vremena prolazi između čuvanja stanja proračuna na permanentnu memoriju
- `--checkpoint-dir=<path>` određuje putanju gde se stanja proračuna čuvaju
- `--restart-dir=<path>` određuje putanja odakle se stanja proračuna učitavaju, osim ako ne radimo nešto jako lukavo ovo je isto kao vrednost prethodne opcije iz očiglednih razloga

`-D` opcija

- Stara se da će se proces pokrenuti u specificiranom direktorijumu, a ne u direktorijumu gde izvršavamo `srun` komandu.

`-p` opcija

- Specificira particiju na kojoj radimo
- Imamo opciju da navedemo više particija razdvojenih dvotačkama

`--mpi` opcija

- SLURM samo može da radi ovo što radi uz pomoć MPI protokola
- Imaju razne implementacije MPI i ova opcija omogućava da se izabere prava
- Za nas, to je manje-više uvek `openmpi`

`-l` opcija

- Trivijalna sa tačke gledišta upravljanja sistemom ali odlična za nas
- `-l` nam daje oznaku na izlazu interaktivnih procesa koja specificira koji se proces startuje

`-K` opcija

- Ako postavimo `-K` indikujemo da ako se bilo koji korak u zadatku završi i vrati ne 0 nego nešto drugo da ceo zadatak stane.
- Ovo je gotovo sigurno dobra ideja.

`salloc` komanda

- Komanda ima iste parametre kao i `srun` i radi nešto vrlo slično.
- Alocira specificirane resurse i pokreće komandu koja je navedena.
- Svrha `salloc` jeste da komanda koju navedemo bude skripta puna `srun` komandi gde `salloc` alocira šta treba za sve zajedno, izvrši ih, i onda dealocira resurse.
- `salloc` je interaktivna komanda

`sbatch` komanda

- Služi za automatsko, grupno izvršavanje posebno dizajniranih skripti
- `Sbatch` komanda podržava izvršavanje bez nadzora i automatski preusmerava ispis na izlazu skripte koju pokreće.
- Čim se izvrši, ona vrati kontrolu korisniku, a resursi se alociraju i posao odradi kasnije.
- Prosleđena skripta se, fizički, pokreće na prvom od alociranih čvorova.
- Izlaz će se naći u fajlovima oblika `slurm-<n>.out` gde je <n> broj posla.

Nizovi poslova

- Jedan vrlo efektan način da se pokrene više stvari istovremeno jeste da se radi sa nizom poslova.
- Ako mi ne želimo da uradimo 30 različitih stvari, recimo, nego istu stvar (sa drugim podacima) 30 puta (što je realistična mogućnost) onda je niz idealan metod.
- Zašto je ovo bolje? Zato što SLURM unapred zna šta to hoćemo da uradimo i mnogo manje napadamo sistem zakazivanja izvršavanja što je slaba tačka SLURM sistema.

Nizovi poslova

- Opcija da zahtevamo niz u sbatch komandi je -a praćena specifikacijom niza praćena opcionim ograničenjem konkurentnosti
  - Specifikacija niza je ili:
  - indeksi razdvojeni zarezima
  - Raspon (tj. dva broja razdvojena crticom, npr. 2-7)
  - Raspon sa korakom (tj. dva broja razdvojena crticom praćena dvotačkom i korakom koji se koristi u brojanju između te dve vrednosti, npr. 2-10:2 što znači od 2 do 10 u koracima po 2)

- Ograničenje konkurentnosti ide posle specifikacije niza i sastoji se od znaka ” posle koga ide broj poslova koji se sme istovremeno izvršavati.

Kontrola imena izlaznih fajlova

- Jako nam je bitno da izlazni fajlovi imaju dobra imena. Zašto? Zato što će tu biti naši (dragoceni) rezultati. Ako ih izgubimo ili prepišemo jedne preko drugih uzalud smo računali.
- `-o` opcija definiše format imena izlaznog fajla sa određenim specijalizovanim simbolima koji se prilikom procesiranja posebno interpretiraju.
- `%A` će biti zamenjen identifikatorom niza
- `%a` će biti zamenjen indeksom posla unutar niza
- `%j` će biti zamenjen jedinstvenim brojem posla (ako ne koristimo nizove)
- `%N` je ime prvog čvora koji je alociran za posao.
- `%u` je ime korisnika koji je sve ovo pokrenuo

Pisanje `sbatch` skripti

- `sbatch` ima posban format za skripte
- U osnovi to su shell skripte iz Unix sveta sa par malih modifikacija
- Glavne modifikacije u odnosu na shell skripte su:
  - Prisustvo posebnih promenljivih koje nam daje `SLURM`
  - `SBATCH` komentari
    - `SBATCH` komentari su komentari koji počinju sa `#SBATCH` is posle kojih ide razmak a onda neki od parametara koji smo radili za `srun` opciju

Shell skripte?

- Shell je kako se zove interpreter koji obrađuje interakciju korisnika sa komandnom linijom.
- Danas je manje-više standard Bourne Again Shell odn. ‘bash.’ (`zsh` je popularan kod programera, ili `fish`, ali se ne koristi za ovakve stvari). Windows preferira `PowerShell`
- Shell skripta je način da se izvrši više korisničkih komandi, tipično na ne-interaktivan način.
- Stari Windows ekvivalent su `.bat` fajlovi.

Format shell skripte

- To je fundamentalno samo tekstualni fajl, ništa više
- Tipična ekstenzija je `.sh`, mada se skripte za `sbatch` često pišu sa `.sbatch` ekstenzijom.
- Ako želimo da se skripta sama izvršava onda mora počinjati sa posebnom linijom:
  - `#!/bin/bash`
  - Linija koja počinje sa `#!` na početku znači "ako pokreneš ovaj fajl kao izvršni, onda pokreni ovu aplikaciju i daj joj sadržaj ovog fajla"
  - Mora biti *puna* putanja do fajla, što je ponekad problem
  - Rešenje: `#!/usr/bin/env python` Env će naći ono što tražimo u našoj PATH sistemskoj promenljivoj

Format shell skripte

- Komentari u shell skriptama počinju sa znakom # i traju do kraja linije
- Sve ostale linije su komande koje se izvršavaju

Promenljive u shell skriptama

- Pišu se svim velikim slovima
- Traju samo u fajlu u kojem se izvršavaju, ali mogu da učitaju vrednosti spolja, tj. iz okruženja shell-a koji skriptu pokreće.
- Da bi ih podesili dovoljno je da napišemo: `MYVAR = "vrednost"`
- Da bi ih iskoristili stavljamo ispred njihovog imena `$`, tako da da bi napravili fajl koji se zove po onome što je u `MYVAR` stavili bi `touch $MYVAR`
- Ako postoji konfuzija oko toga gde se ime promenljive završava koriste se velike zagrade ovako

```
MYVAR="vrednost"
I="4"
```

```
touch ${MYVAR}_${I}
```

Linux sistemske promenljive

- Ako hoćemo da naša promenljiva bude dostupna šire, sve što treba da uradimo jeste da ispred dodele vrednosti promenljive stavimo `export` ovako:
- `export A="vrednost"`
- Ovako se podešava mnogo stvari u Linux sistemima: kada se ulogujete izvrše se skripte (`.bashrc` i `.profile`) koje izpodešavaju razne sistemske promenljive na takav način da su dostupne svakom programu koji pokrenete kao pod-proces procesa koji je pozvao `export` (što je svaki program ako je `export` pozvao `login shell`).

Primer `SBATCH` skripte

```
#!/bin/bash

#SBATCH -J ime
#SBATCH -p particija1
#SBATCH -n 1
#SBATCH -N 1
#SBATCH -t 0-02:00 #radimo 2 sata
#SBATCH --mem 4000
#SBATCH -o ime_%A_%a.out
#SBATCH -e ime_%A_%a.err

mkdir dir${SLURM_ARRAY_TASK_ID}_out
cd dir${SLURM_ARRAY_TASK_ID}_out

../prg/program
```

Promenljive

Promenljiva	Značenje
SLURM_NTASKS	Šta je prosleđeno -N opciji
SLURM_NTASKS_PER_CORE	Šta je prosleđeno --ntasks_per_core opciji
SLURM_NTASKS_PER_NODE	Šta je prosleđeno --ntasks_per_node opciji
SLURM_NTASKS_PER_SOCKET	Šta je prosleđeno --ntasks_per_socket opciji
SLURM_CPUS_PER_TASK	Šta je prosleđeno -c opciji
SLURM_DISTRIBUTION	Šta je prosleđeno -m opciji
SLURM_JOB_DEPENDENCY	Šta je prosleđeno -d opciji

Promenljive

Promenljiva	Značenje
SLURM_NNODES	Broj čvorova alociranih za posao
SLURM_JOB_CPUS_PER_NODE	Koliko imamo CPU-ova na ovom čvoru
SLURM_CPUS_ON_NODE	Koliko ima CPU-ova na ovom čvoru ukupno.
SLURM_SUBMIT_HOST	Ime računara odakle potiče zadatak
SLURM_CLUSTER_NAME	Ime klastera gde se posao izvršava
SLURM_JOB_PARTITION	Ime particije gde se posao izvršava
SLURM_JOBID	ID trenutnog zadatka
SLURM_LOCALID	PID trenutnog procesa na čvoru

Promenljive

Promenljiva	Značenje
SLURM_NODEID	ID tekućeg čvora
SLURM_PROCID	Globalno-validan ID procesa
SLURM_JOB_NODELIST	Lista svih čvorova alociranih zadatku
SLURM_TASKS_PER_NODE	Koliko se stvari izvršava na svakom čvoru
SLURM_ARRAY_TASK_ID	Niz indeksa zadatak u okviru niza, ako ga ima

Promenljiva	Značenje
SLURM_ARRAY_TASK_MIN	Najmanji indeks niza, ako ga ima
SLURM_ARRAY_TASK_MAX	Najveći indeks niza, ako ga ima
SLURM_ARRAY_TASK_STEP	Korak u brojanju indeksa niza
SLURM_ARRAY_JOB_ID	ID celog niza, ako ga ima

Jednostavan primer upotrebe SLURM promenljivih

```
#!/bin/bash
export OMP_NUM_THREADS=$SLURM_CPUS_PER_TASK
./omp_program
```