

OpenACC

Рачунарски системи високих перформанси

Горана Гојић Вељко Петровић

Факултет техничких наука
Универзитет у Новом Саду

Рачунарске вежбе, Зимски семестар 2018/2019.



Шта је OpenACC

API за пребацивање извршавања делова кода на акцелератор.
Обухвата:

- директиве (`pragma acc <direktiva>`)
- променљиве окружења (енг. *runtime environment variables*)
- библиотечке рутине (енг. *library routines*)

Подршка за **C**, **C++** и **Fortran**.

Концептуално веома сличан OpenMP.

Акцелератори.



У лабораторији ћемо као акцелератор користити *Nvidia Quadro* графичке картице.

OpenACC компјалери

Commercial Compilers



Contact Cray Inc for more information.



Annual license. Free download.



Contact National Supercomputing Center in Wuxi for more information.

Open Source Compilers



GCC 7
Includes initial support for OpenACC 2.5

Academic Compilers



Omni compiler project,
RIKEN/University of Tsukuba



OpenARC, Oak Ridge National Laboratory



OpenUH, University of Houston,
Stony Brook University



ROSEACC, LLNL/University of Delaware

На вежбама ћемо користити GNU GCC компјалер.

¹Извор OpenACC званична страна

Компајлирање OpenACC програма

Позиционирати се у директоријум у којем се налази датотека са OpenACC кодом и у терминалу унети:

```
gcc -o izvrsna_dat izvorna_dat.c -fopenacc
```

За покретање програма, позиционирати се у директоријум у којем је извршна датотека и унети `./izvrsna_dat`.

Уколико програм позива неку од OpenACC функција (назив почиње са `acc_`), у изворну датотеку је потребно додати и

```
#include <openacc.h>
```

.

Домаћин (енг. *Host*) - централна процесна јединица са својом хијерархијом меморије.

Акселератор (енг. *Accelerator* или *Device*) - акселераторски уређај, нпр. графичка картица.

Паралелни регион - Део кода обележен за извршавање на акцелераторском уређају са придруженим структурама података. Обухвата регионе кода обележене `parallel` и `kernels` директивама (другачије ће се звати и рачунски региони).

OpenACC модел извршавања




Figure: Концептуална архитектура акселератора

OpenACC подржава три нивоа паралелизма: *gang*, *worker*, *vector*

Општи формат OpenACC директиве:

```
#pragma acc <directive> [clause-list] new-line  
structured block
```

Директиве за обележавање паралелног кода:

- kernels
- parallel

kernels директива

Означава део кода који може бити преведен за извршавање на акцелератору прављењем једног или више кернела. Компајлер одлучује **шта** ће и **како** ће паралелизовати.

```
#pragma acc kernels [clause-list] new-line  
structured block
```

Неке од клаузула (параметри нису наведени):

- async
- wait
- copy
- copyin
- copyout
- ...

Пример 1: kernel.c

```
int main() {  
  
    /* ... */  
  
    #pragma acc kernels  
    {  
        for(i = 0; i < MATRIX_SIZE; i++)  
            for(j = 0; j < MATRIX_SIZE; j++)  
                randomMatrix[i * MATRIX_SIZE + j] =  
                    randomMatrix[i * MATRIX_SIZE + j] * 2;  
    }  
  
    return 0;  
}
```

Пример 2: ptraliasing.c

```
void assign(int *a, int *b, int size) {  
    #pragma acc kernels  
    {  
        for (int i = 0; i < size - 1; i++)  
            a[i] = b[i + 1];  
    }  
}
```

Питање: Када се користи `kernels` директива, компајлер проналази делове кода који су безбедни за паралелизацију, односно, у којима нема зависности међу подацима. Шта мислите, да ли би OpenACC компајлер превео ово у код за паралелно извршавање?

parallel директива

Означава део кода који ће бити преведен за извршавање на акцелератору. Компајлер одређује **како** ће сегмент кода бити паралелизован. Подразумевано извршавање креће у *gang-redundant* режиму.

```
#pragma acc parallel [clause-list] new-line  
structured block
```

Неке од клаузула (параметри нису наведени):

- async
- wait
- num_gangs
- num_workers
- vector_length
- reduction
- copy
- copyin
- copyout
- ...

Пример 3: parallel.c

```
#include <openacc.h>

int main() {
    float *values = (float *) malloc(sizeof(float) * size);

    #pragma acc parallel
    for (int i = 0; i < 1024; i++)
        values[i] = 1.f;
    free(values);

    return 0;
}
```

Питање: Колико пута ће сваком пољу value низа бити додељена вредност?

parallel клаузуле

- **async** - Нит која је наишла на `parallel` или `kernels` директиву (локална нит) може да настави извршавање кода који следи иза паралелног региона без чекања да уређај заврши свој посао.
- **wait** - Када наиђе на ову клаузулу, локална нит чека.
- **num_gangs(int-exp)** - Број *gang*-ова који извршавају паралелни регион.
- **num_workers(int-exp)** - Број радника унутар *gang*-а.
- **vector_length(int-exp)** - Дужина вектора која се користи за SIMD операције.
- **reduction(op:var-list)** - Прави локалну копију променљиве и иницијализује је. На крају паралелног региона се локалне копије редукују.
- **copy, copyin, copyout**

loop директива

Даје компајлеру додатне информације о томе како да паралелизује петљу на коју се односи директива. Може бити унутар `parallel` или `kernels` директива.

```
#pragma acc loop [clause-list] new-line  
for loop
```

Комбиноване конструкције:

```
#pragma acc parallel loop [clause-list] new-line  
for loop
```

```
#pragma acc kernels loop [clause-list] new-line  
for loop
```

loop клаузуле

Клаузуле за оптимизацију извршавања:

- **gang** - Партиционише итерације између *gang*-ова. Преводи извршавање из *gang-redundant* у *gang-partitioned* режим. У случају угњеждених петљи, спољна мора бити *gang* петља.
- **worker** - Патриционише итерације између *worker*-а. Преводи извршавање из *worker-single* у *worker-partitioned* режим. У случају угњеждених петљи, било која унутрашња петља, осим оне најугњежденије, може бити *worker* петља.
- **vector** - Векторизација петље (*SIMD* или *SIMT*). У случају угњеждених петљи, најугњежденија је *vector* петља.
- **seq** - Петља ће се извршити секвенцијално без обзира на потенцијалне оптимизације које је компајлер пронашао. У сучају угњеждених петљи, може бити на било ком нивоу.

Оптимизацијом петљи се губи на портабилности програма.

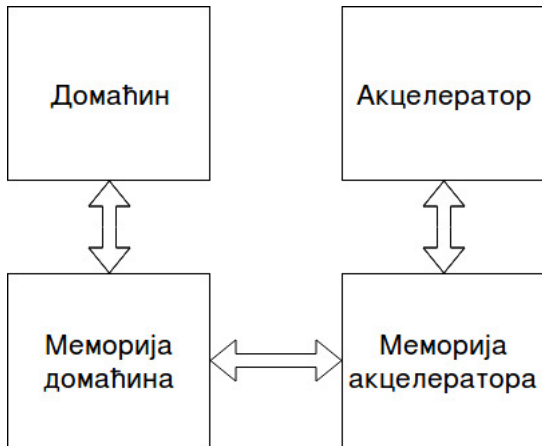
Остале клаузуле:

- **private**
- **reduction**
- **independent** - Сигнализира компајлеру да нема зависности података између итерација петље.
- ...


Пример 4: parallelloop.c

```
int main() {  
  
    /* ... */  
  
    #pragma acc parallel loop gang  
    for (int i=0; i<N; i++)  
        #pragma acc loop vector  
        for (int j=0; j<M; j++)  
            A[i * N + j] = 1.f;  
  
    return 0;  
}
```

Модел података



Утицај модела података на перформансе



Оптимизација кернела без оптимизације преноса података обично не води побољшању перформанси извршавања програма!

¹Извор: OpenACC Programming and Best Practices Guide

Пренос података између домаћина и уређаја је могуће контролисати на више начина:

- Без било каквог специфицирања понашања, компајлер ће сам одредити када и које податке треба пренети са домаћина на уређај или обрнуто.
- Модификовањем понашања `parallel` и `kernels` одговарајућим клаузулама за рад са подацима (нпр. `copy`, `copyin`, `copyout`...). Модификације важе за паралелни регион над којим су примењене клаузуле за модификацију.
- Коришћењем `data` директиве.
- Коришћењем `data enter` и `data exit` директива (углавном за објектно програмирање).

data директива

Дефинише блок кода у којем се клаузулама контролише пренос података на релацији домаћин уређај.

```
#pragma acc data [clause-list] new-line  
structured block
```

- copy
- copyin
- copyout
- create
- present

Пример 5: data.c

```
int main() {  
    /* ... */  
    #pragma acc data  
    {  
        #pragma acc parallel loop  
        for (int i=0; i<N; i++) {  
            y[i] = 0.0f;  
            x[i] = (float)(i+1);  
        }  
        #pragma acc parallel loop  
        for (int i=0; i<N; i++) {  
            y[i] = 2.0f * x[i] + y[i];  
        }  
    }  
    /* ... */  
}
```

- **copy(var-list)** - Алоцира простор за променљиве на уређају, копира вредности са домаћина на уређај и са уређаја назад на домаћина када се заврши блок података (или `parallel` и `kernels` блок ако клаузула стоји уз њих)
- **copyin(var-list)** - Алоцира простор за променљиве на уређају и копира вредности са домаћина на уређај. По завршетку блока не преноси вредности назад на домаћина.
- **copyout(var-list)** - Алоцира простор за променљиве на уређају без иницијализације подацима са домаћина. По завршетку блока, подаци се преносе са уређаја на домаћина.
- **create(var-list)** - Алоцира простор за променљиве на уређају без иницијализације. Вредности променљивих се на крају блока не пребацују на домаћина.
- **present(var-list)** - Означава да су променљиве присутне у меморији уређаја.

GNU GCC компајлер:

- ACC_DEVICE_TYPE (стандард)
- ACC_DEVICE_NUM (стандард)
- ACC_PROF (стандард)
- GOPMP_OPENACC_DIM (gcc)
- GOMP_DEBUG (gcc)

Задатак 1: Рачунање броја π

Модификовати дати секвенцијални програм за рачунање вредности броја π коришћењем OpenACC директива. Користити NVIDIA графичку картицу као акцелератор (GNU GCC тренутно не подржава Radeon картице). Мерити извршавање секвенцијалног и имплементираног убрзаног програма.

Напомена: Задатак свакако имплементирати и у случају да на рачунару немате доступну NVIDIA графичку картицу.

Задатак 2: Рачунање Јакобијана

Модификовати дати секвенцијални програм за рачунање Јакобијана. Основну верзију програма у C++ програмском језику скинути са Гитхаб налога OpenACCUserGroup. Користити NVIDIA графичку картицу као акцелератор (GNU GCC тренутно не подржава Radeon картице). Мерити извршавање секвенцијалног и имплементираног убрзаног програма.

Напомена: Задатак свакако имплементирати и у случају да на рачунару немате доступну NVIDIA графичку картицу.

Савети за инкрементално портовање секвенцијалног у OpenACC код

- ❶ Идентификовати паралелизам петљи. Паралелизовати део по део секвенцијалног кода при том контролишући коректност извршавања програма. Наставити са овим типом оптимизације без обзира на то да ли се време извршавања повећава.
- ❷ Оптимизовати пренос података. Преклопити пренос података са рачунањем, уклонити непотребна копирања, ажурирања променљивих, итд...
- ❸ Паралелизоване петље оптимизовати за циљну архитектуру коришћењем клаузула.

¹Извор: OpenACC Programming and Best Practices Guide 

Текстуални материјали:

- OpenACC Programming and Best Practices Guide
- OpenACC Specification 2.5
- GNU GCC OpenACC Wiki
- David B. Kirk, Wen-mei W. Hwu, *Programming Massively Parallel Processors, A Hands on Approach*, 2nd edition, 2012

Видео туторијали:

- Introduction to Parallel Programming with OpenACC
- Advanced OpenACC